



# КУМПАН ВИКТОР ВИКТОРОВИЧ

Junior/middle Deep learning / Data science / Software engineering

## ЦЕЛЬ

Совершенствование, развитие профессиональных компетенций и навыков командной разработки продукта. Внести вклад в развитие вашей компании!

## ОБРАЗОВАНИЕ

### НИУ ИТМО Г. САНКТ-ПЕТЕРБУРГ • 2019-2023 БАКАЛАВРИАТ

Факультет информационных технологий и программирования ФИТиП, направление подготовки прикладная математика и программирование. Средний балл 4.9. В рейтинге студентов в 5 лучших (за весь период обучения).

## НАВЫКИ

- Владение английским B2 (Upper Intermediate)
- Математический и функциональный анализ, дискретная математика.
- DevOps - CI/CD. Опыт работы с Docker, GIT.
- Алгоритмы и структуры данных (STL)
- Python, C++, ООП, Функционального программирования.
- PyTorch, TensorFlow, NumPy, Scikit-learn,
- Pandas, Matplotlib, Seaborn
- SQL и опыт проектирование БД
- AWS, Azure, OpenStack.
- Умение стремительно развиваться в высококвалифицированном окружении
- Понимание принципов ведения проектов Kanban, Scrum, Agile.

## ОПЫТ ПРОДУКТОВОЙ И ПРОЕКТНОЙ РАБОТЫ

### SAMSUNG COMPUTER VISION ENGINEER • ВОССТАНОВЛЕНИЕ МОЗАИЧНЫХ ИЗОБРАЖЕНИЙ ПОЛУЧЕННЫХ С МАТРИЦ ТЕЛЕФОНОВ.

**Задача:** Оптимизация процесса тренировки и инференса моделей (Pipeline) для улучшения качеств моделей и повышения продуктовых метрик.

**Результат:** Решены задачи с оптимизацией pipeline, выведены функции оптимизации моделей (VAE, GAN, AE), улучшающие продуктовые метрики. Адаптированы аугментации под целевую задачу. Проведен рефакторинг кода и сделан более юзабельный pipeline.

### YANDEXCUP COMPUTER VISION • СОПОСТАВЛЕНИЕ ИЗОБРАЖЕНИЙ К НАИБОЛЕЕ РЕЛЕВАНТНОМУ ТЕКСТОВОМУ ОПИСАНИЮ / ZERO-SHOT.

В рамках турнира предоставлен датасет из ссылок на изображения (5 млн) и соответствующим им поисковым запросам (>20 млн). Написано простое MLOps решение для:

- Многопоточного скачивания, обработки (аугментации) данных, анализа текстовых данных, кластеризации текстовых описаний и визуализации embeddings
- Обучения моделей I2T zero-shot classification, создание моделей кластеризации (Train: BoW -> SentenceTransformer -> AgglomerativeClustering -> KNeighborsClassifier; Inf: SentenceTransformer -> KNeighborsClassifier)
- Оценка качества моделей, легирование (tensorboard)



@SKYLARPRO



SKYLARPRO



+79508998389



ITMO

## ○ Inference

За baseline взят CLIP by Sber (visual\_encoder – ViT-B32; text\_encoder – GPT3Small) так как он влез в ограничения по весу модели. С коробки accuracy на private 42%, также пробовал заменить GPT3Small -> RuBert ; GPT3Small -> BPE embeddings (предоставленные организаторами) + 4 transformers block. Финальным решением было приделать к baseline параллельный классификатор [1, N], класс которого соответствовал номеру projections стоявшего на выходе text\_encoder (тренировка End-to-End). Это позволило поднять точность на семантически близких описаниях. В итоге accuracy на private возросло до 58%. Более подробно на github.

## **AI JOURNEY 16 МЕСТО (БРОНЗА) • AI TRAIN ДЕТЕКЦИЯ, СЕГМЕНТАЦИЯ ОБЪЕКТОВ НА ЖД-ИНФРАСТРУКТУРЕ**

В рамках турнира предоставлен датасет из 11 классов детекции и 3-х классов для сегментации. Проведен статистический анализ данных. Для детекции объектов был взят YOLOV5 (bb – EfficientNet; Neck – Bi-FPN; Head – Conv), выполнена легкая аугментация данных, так как некоторые классы оказались чувствительны. Выполнена тонкая настройка NN (freeze bb) и подбор гиперпараметров. В начале тренировок loss взял CE, далее перешел к FL, это помогло поднять f-score для отстающих классов. Для сегментации использовал в качестве encoder ResNet-18, decoder – Unet тренировал с помощью CE, но после оптимизации перешел на JaccardLoss. Качество оценивалось как competition\_metric = 0.7 \* mAP@.5 + 0.3 \* meanIoU. CM на Baseline было 0.41, удалось повысить до 0.47.

## **СТАРТАП (БИЗНЕС КЕЙС) • АНАЛИЗ “ТОНАЛЬНОСТИ” ПОСТОВ В СОЦИАЛЬНЫХ СЕТЯХ**

Поставлена бизнес задача, выделены ключевые особенности решений и сопоставлены бизнес и ML метрики. Размечен датасет совместно с экспертами. Произведен preprocessing, анализ текста. Начали с классического ML: LogRegCV, AdaBoost, SVM с различными vectorizers TF-IDF, CountVect. Данным подходом получили f-меру порядка 75 %. В качестве DL BaseLine взята архитектура BERT. Проблема ограниченного количества данных решена аугментацией и подбором pre-train моделей для смежных задач. Удалось поднять f-меры до 85%.



## НАУЧНО-ИССЛЕДОВАТЕЛЬСКАЯ РАБОТА • ВЛИЯНИЕ ADVERSARIAL ATTACKS НА СНИМКИ МРТ МОЗГА

Работа была проведена на датасете Brats (3d снимки мозга), выполнен анализ данных, за основу была взята CNN ResNet-18. Произведена кастомизация архитектуры под 3d изображения с применением transfer learning. Выполнена тренировка CNN с различными функциями активации ReLu и BReLU и ее тонкая настройка. Для проверки гипотез была произведена аугментация данных, тренировка CNN на FGSM атаках. Удалось достичь F-меру порядка 94%.

## НАУЧНО-ИССЛЕДОВАТЕЛЬСКАЯ РАБОТА • ДЕТЕКЦИЯ ДЕФЕКТОВ СТАЛИ

Работа была проведена на датасете “Северсталь”, задача сегментации. За основу был взят U-net decoder и Res-Net 18 encoder, выполнена тонкая настройка NN. Произведен анализ датасета на возможные корреляции и дисперсию в данных. Выполнена аугментация данных и их предобработка. Качество модели проверял на IoU – удалось достичь порядка 65 % на валидации. Было применены методы борьбы с overfitting. Выполнена визуализация работы NN.

## ПРИКЛАДНОЕ ПРОГРАММИРОВАНИЕ • C ++

1. Реализация шаблонного вектора со всеми основными операциями и с динамическим освобождением памяти.
2. Реализация нагруженного дерева (trie, бор) с упором на время выполнения и потребляемую память.
3. Реализация игры морской бой на основе принципа ООП и написание умного бота для игры. Виртуализация.
4. Реализация умной телефонной книги на основе STL, оптимизированной по времени работы и по памяти.
5. Реализация решателя sudoku (количество решений, решение) оптимизировано по времени и по памяти.

## ПРИКЛАДНОЕ ПРОГРАММИРОВАНИЕ • PYTHON

1. Первое место на Всероссийском конгрессе молодых ученых. Софт для автоматизированного поиска в открытых научных источниках информации для исследования предметной области.



2. Реализация игры жизнь, на основе ООП, работа с GUI и пользовательским интерфейсом.
3. Реализация системы контроля версии с основными командами и принципами работы.
4. Реализация пула процессов с управлением памятью и рабочими, если память во время вычислений выходит за пределы выделенной, то этот расчет отправляется и обрабатывается во втором раунде.
5. Реализация веб-сервиса “записной книжки” на Django, с реализацией REST API и упаковкой в Docker контейнер и покрытием Unit tests .

## МАТЕМАТИЧЕСКИЕ МЕТОДЫ МАШИННОГО ОБУЧЕНИЯ • PYTHON

1. Реализация **DecisionTree** с возможностью выбора основных гиперпараметров, на основе этого дерева реализация **RandomForest** с возможностью выбора основных гиперпараметров.
2. Реализация **Polynomial regression, Linear regression** с возможностью как аналитического решения, так и итерационного. Визуализация решений и применение на реальных данных.
3. Реализация нейрона с различными функциями активации Sigmoid(LogLoss), ReLu, LeakyReLu, ELU (MSELoss).
4. Реализация **Naive Bayes Classifier**.
5. Работа с основными библиотеками Pandas, NumPy, PyTorch.

